

UNIVERSIDADE DE UBERABA - UNIUBE
CAMPUS UBERLÂNDIA

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

KENZO RAMOS OTAGUIRI

**Aplicação de Inteligência Artificial no mapeamento de vigor vegetativo em lavouras
utilizando imagens de drones**

Uberlândia

2026

KENZO RAMOS OTAGUIRI

**Aplicação de Inteligência Artificial no mapeamento de vigor vegetativo em lavouras
utilizando imagens de drones**

Trabalho apresentado à disciplina Inteligência Artificial do bacharelado em sistemas de informação da Universidade de Uberaba, como requisito parcial para a obtenção de nota.

Orientador: Prof. Igor Cortes Alves Junqueira

Uberlândia

2026

RESUMO

A agricultura de precisão tem se destacado como uma importante estratégia para otimizar a produção agrícola e reduzir custos operacionais. Diante disso, o uso de drones para captura de imagens aéreas permite o monitoramento eficiente de grandes áreas cultivadas. No entanto, a análise manual dessas imagens apresenta limitações, sendo necessária a aplicação de técnicas automatizadas. O presente trabalho tem como objetivo desenvolver um sistema baseado em inteligência artificial capaz de analisar imagens agrícolas obtidas por drones, realizar sua classificação automática e estimar o vigor vegetativo por meio da análise da cobertura vegetal presente nas imagens. A metodologia adotada consiste na utilização de imagens agrícolas obtidas por drones como base de dados, aplicação de técnicas de processamento de imagens e uso de Redes Neurais Convolucionais para classificação automática das imagens e estimativa do vigor vegetativo. Os resultados obtidos demonstram que o sistema foi capaz de identificar padrões de variação na vegetação, permitindo destacar regiões com diferentes níveis de vigor. Observou-se que a aplicação da Inteligência Artificial contribui significativamente para a automatização da análise agrícola, proporcionando maior rapidez e precisão na identificação de problemas. Portanto, a utilização de IA associada a drones apresenta grande potencial para auxiliar na tomada de decisões no campo, promovendo maior eficiência na gestão agrícola e contribuindo para o avanço da agricultura de precisão.

Palavras-chave: Inteligência Artificial. Agricultura de precisão. Drones. Visão computacional.

LISTA DE FIGURAS

Figura 1 - Evolução da acurácia durante o treinamento da CNN	14
Figura 2 - Evolução do erro (Loss) durante o treinamento.....	14
Figura 3 - Matriz de confusão do modelo CNN	15
Figura 4 - Interface do sistema desenvolvido	16
Figura 5 - Exemplo de classificação realizada pela IA	17
Figura 6 - Identificação automática da cobertura vegetal e estimativa do vigor vegetativo	18

SUMÁRIO

1 INTRODUÇÃO	5
1.1 Problema da pesquisa	5
1.2 Objetivos	6
1.2.1 Objetivo geral	6
1.2.2 Objetivos específicos	6
1.3 Justificativa.....	6
1.4 Estrutura do trabalho	6
2 REFERENCIAL TEÓRICO	8
2.1 Inteligência Artificial.....	8
2.2 Redes Neurais Convolucionais (CNN)	8
2.3 Agricultura de Precisão	8
2.4 Uso de Drones no Monitoramento Agrícola	9
2.5 Visão Computacional Aplicada à Agricultura.....	10
3 METODOLOGIA.....	11
4 DESENVOLVIMENTO E EVOLUÇÃO	13
5 CONCLUSÃO.....	19

1 INTRODUÇÃO

A agricultura tem passado por transformações significativas nas últimas décadas, impulsionadas pelo avanço tecnológico e pela necessidade de aumentar a produtividade, reduzir custos operacionais e minimizar impactos ambientais. Nesse cenário, a agricultura de precisão vem se destacando como uma abordagem estratégica, pois utiliza diferentes tecnologias para monitorar, analisar e otimizar o manejo das lavouras de forma mais eficiente e inteligente.

Entre as ferramentas mais utilizadas nesse contexto, destacam-se os drones, que permitem a captura de imagens aéreas de grandes áreas agrícolas com rapidez, precisão e menor custo quando comparados a métodos tradicionais de monitoramento. A partir dessas imagens, é possível observar falhas no plantio, diferenças no desenvolvimento das culturas e possíveis sinais de estresse vegetativo. Entretanto, a interpretação manual dessas imagens pode ser demorada, limitada e sujeita a erros, especialmente em áreas extensas.

Diante dessa realidade, a Inteligência Artificial surge como uma alternativa promissora para automatizar a análise das imagens obtidas por drones. Por meio de técnicas de processamento de imagens e aprendizado de máquina, torna-se possível identificar padrões visuais relacionados à saúde da vegetação e gerar mapas que auxiliem na tomada de decisão no campo. Dessa forma, a integração entre drones e Inteligência Artificial pode contribuir de maneira relevante para a agricultura de precisão, tornando o monitoramento agrícola mais rápido, preciso e eficiente.

Este trabalho propõe a aplicação da Inteligência Artificial no mapeamento de lavouras a partir de imagens captadas por drones, com foco na identificação de diferentes níveis de vigor vegetativo. A proposta busca demonstrar como o uso de tecnologias computacionais pode auxiliar o produtor rural no acompanhamento das culturas e no gerenciamento das áreas agrícolas, contribuindo para um manejo mais assertivo.

1.1 Problema da pesquisa

O problema central deste trabalho consiste em responder à seguinte questão: como identificar automaticamente, por meio de imagens captadas por drones, áreas de lavoura com diferentes níveis de vigor vegetativo?

A relevância desse problema está no fato de que a análise manual nem sempre é suficiente para interpretar com precisão grandes volumes de imagens agrícolas. Assim, torna-se necessário o desenvolvimento de uma solução automatizada capaz de transformar dados visuais em informações úteis para o monitoramento da plantação.

1.2 Objetivos

1.2.1 Objetivo geral

Desenvolver um sistema baseado em Inteligência Artificial capaz de analisar imagens agrícolas obtidas por drones, realizar sua classificação automática e estimar diferentes níveis de vigor vegetativo.

1.2.2 Objetivos específicos

Identificar a importância do uso de drones no monitoramento agrícola.

Apresentar os conceitos fundamentais de Inteligência Artificial aplicados à análise de imagens.

Utilizar imagens de lavouras como base para o desenvolvimento da proposta.

Aplicar técnicas de processamento de imagens e aprendizado de máquina na classificação das áreas analisadas.

Demonstrar como a solução proposta pode auxiliar na agricultura de precisão e na tomada de decisão no campo.

1.3 Justificativa

A escolha desse tema se justifica pela crescente necessidade de modernização do setor agrícola, especialmente no que se refere ao uso eficiente de recursos e ao monitoramento das lavouras em tempo real. A agricultura de precisão vem ganhando cada vez mais espaço por possibilitar um manejo mais detalhado e estratégico das áreas cultivadas, favorecendo o aumento da produtividade e a redução de desperdícios.

Nesse contexto, os drones representam uma importante ferramenta de coleta de dados, pois possibilitam uma visão ampla e detalhada da lavoura. No entanto, a simples obtenção das imagens não resolve o problema, já que é necessário interpretar essas informações de forma rápida e confiável. É nesse ponto que a Inteligência Artificial se destaca, oferecendo meios de automatizar a análise e extrair padrões relevantes a partir das imagens coletadas.

Além da relevância prática para o setor agrícola, o tema também possui importância acadêmica, pois reúne conceitos de Inteligência Artificial, visão computacional e agricultura de precisão em uma aplicação concreta e atual. Assim, este estudo contribui para demonstrar o potencial dessas tecnologias na resolução de problemas reais, reforçando sua utilidade no desenvolvimento de soluções inovadoras para o campo.

1.4 Estrutura do trabalho

O presente trabalho está organizado em capítulos que abordam os principais aspectos da pesquisa. No primeiro capítulo, apresenta-se a introdução, contemplando a contextualização do tema, o problema de pesquisa, os objetivos e a justificativa.

No segundo capítulo, será desenvolvido o referencial teórico, com a apresentação dos conceitos que fundamentam o estudo, incluindo Inteligência Artificial, agricultura de precisão, uso de drones na agronomia e visão computacional.

Nos capítulos seguintes, serão descritos os procedimentos metodológicos, o desenvolvimento da proposta e as considerações finais sobre os resultados esperados e a relevância da solução apresentada.

2 REFERENCIAL TEÓRICO

2.1 Inteligência Artificial

A Inteligência Artificial (IA) é um ramo da ciência da computação dedicado ao desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiram inteligência humana, como reconhecimento de padrões, aprendizado, tomada de decisões e resolução de problemas. Segundo Russel e Norvig (2021), a IA pode ser definida como o estudo de agentes inteligentes capazes de perceber o ambiente e agir racionalmente para alcançar determinados objetivos.

Nas últimas décadas, o avanço do poder computacional e a disponibilidade de grandes volumes de dados contribuíram significativamente para o crescimento de inteligência artificial. Entre as principais áreas da IA destaca-se o Aprendizado de Máquina (Machine Learning), técnica que permite aos sistemas apresentem a partir de exemplos sem serem explicitamente programados para cada situação específica.

De acordo com o Goodfellow, Bengio e Courville (2016), o aprendizado profundo (Deep Learning) representa uma evolução do aprendizado de máquina tradicional, utilizando múltiplas camadas neurais capazes de identificar padrões complexos em grandes conjuntos de dados. Atualmente, essas técnicas são amplamente empregadas em áreas como saúde, indústria, segurança, transporte e agricultura.

2.2 Redes Neurais Convolucionais (CNN)

As Redes Neurais Convolucionais (Convolutional Neural Networks - CNN) constituem uma das principais arquiteturas utilizadas em problemas de visão computacional e reconhecimento de imagens. Segundo LeCun, Bengio e Hinton (2015), as CNNs são capazes de extrair automaticamente características relevantes de imagens por meio de camadas Convolucionais e de agrupamento (pooling).

Diferentemente dos métodos tradicionais de processamento de imagens, as CNNs eliminam a necessidade de extração manual de características, permitindo que o próprio modelo identifique padrões relevantes durante o treinamento. Essa característica torna as CNNs especialmente adequadas para tarefas de classificação, detecção de objetos e segmentação de imagens.

No contexto agrícola, as CNNs tem sido amplamente utilizada para identificação de doenças em plantas, classificação de culturas, monitoramento de produtividade e análise do vigor vegetativo, apresentando elevados indices de precisão e eficiência (LECUN; BENGIO; HINTON, 2015).

2.3 Agricultura de Precisão

A agricultura de precisão pode ser definida como um conjunto de práticas e tecnologias destinadas ao monitoramento detalhado das variabilidades espaciais e temporais existentes em

áreas agrícolas. Segundo Molin (2015), essa abordagem busca aumentar a produtividade e reduzir custos por meio da aplicação localizada de insumos e da tomada de decisões baseadas em dados.

O crescimento populacional mundial tem aumentado a demanda por alimentos, tornando necessária a adoção de tecnologias capazes de elevar a eficiência produtiva das lavouras. Nesse cenário, a agricultura de precisão utiliza recursos como sensores, sistemas de posicionamento global (GPS), drones e algoritmo computacionais para monitorar continuamente as condições das culturas.

A utilização dessas tecnologias permite identificar áreas com deficiência nutricional, estresse hídrico, presença de pragas e falhas de desenvolvimentos, contribuindo para um manejo agrícola mais eficiente e sustentável (MOLIN, 2015).

2.4 Uso de Drones no Monitoramento Agrícola

Os Veículos Aéreos Não Tripulados (VANTs), popularmente conhecidos como drones, tornaram-se ferramentas importantes para a agricultura moderna devido a sua capacidade de coletar imagens de alta resolução em curtos intervalos de tempo.

Segundo Zhang e Kovacs (2012), os drones oferecem uma alternativa de baixo custo em comparação aos métodos tradicionais de monitoramento agrícola, possibilitando a obtenção de informações detalhadas sobre o estado das culturas.

As imagens capturadas pelos drones podem ser utilizadas para diversas finalidades, incluindo identificação de falhas no plantio, monitoramento do crescimento das plantas, detecção precoce de doenças e análise do vigor vegetativo. Além disso, a elevada resolução espacial dessas imagens permite análises mais detalhadas do que aquelas obtidas por satélites (ZHANG; KOVACS, 2012).

No presente trabalho, as imagens capturadas por drones constituem a principal fonte de dados utilizada para treinamento da Rede Neural Convolucional desenvolvida.

2.5 Visão Computacional Aplicada à Agricultura

A visão computacional é uma subárea da Inteligência Artificial dedicada a interpretação automática de imagens e vídeos por sistemas computacionais. Conforme SZELISKI (2022), o objetivo da visão computacional é permitir que máquinas compreendam informações visuais de maneira semelhante à percepção humana.

Na agricultura, a visão computacional tem sido empregada para classificação de culturas, monitoramento da saúde das plantas, identificação de pragas e doenças, análise de produtividade e automação de processos agrícolas (SZELISKI, 2022).

A integração entre visão computacional, drones e redes neurais convolucionais permite o desenvolvimento de sistemas capazes de processar grandes quantidades de imagens agrícolas em curto período de tempo, reduzindo a necessidade de inspeções manuais e aumentando a precisão das análises realizadas (SZELISKI, 2022).

3 METODOLOGIA

A presente pesquisa caracteriza-se como aplicada, de natureza tecnológica e com abordagem quantitativa, uma vez que busca desenvolver uma solução baseada em inteligência artificial para classificação automática de imagens agrícolas obtidas por drones. O objetivo consiste em demonstrar a viabilidade de utilização de Redes Neurais Convolucionais (CNN) para identificação e classificação de diferentes condições agrícolas presentes nas imagens analisadas. Para o desenvolvimento do projeto foi utilizado o ambiente Google Colab, uma plataforma baseada em nuvem amplamente empregada em aplicações de aprendizado de máquina devido à disponibilidade de recursos computacionais e integração com biblioteca de Inteligência Artificial.

A linguagem de programação utilizada foi Python, em conjunto com as bibliotecas TensorFlow e Keras, responsáveis pela construção, treinamento e validação da Rede Neural Convolucional. Também, foram utilizadas bibliotecas auxiliares, como NumPy para a manipulação de dados numéricos, Matplotlib para geração de gráficos e Scikit-Learn para cálculos das métricas de desempenho do modelo.

Como base de dados foi utilizado um conjunto contendo 1.927 imagens agrícolas obtidas por Veículos Aéreos Não Tripulados (VANTs), popularmente conhecidos como drones. As imagens estavam organizadas em quatro classes distintas:

- Dolomite gypsum;
- Fallow (left bare);
- Indian mustard (Brassica Juncea);
- Rice husk charcoal

Para o treinamento do modelo, o conjunto de dados foi dividido automaticamente em duas partes. Foram utilizadas 1.542 imagens para o treinamento da rede neural, correspondendo a aproximadamente 80% do total de imagens disponíveis. As 385 imagens restantes foram destinadas ao processo de validação, representando aproximadamente 20% do conjunto de dados.

Antes do treinamento, todas as imagens foram redimensionadas para 128x128 pixels, garantindo padronização dos dados de entrada da rede neural. Em seguida, foi realizada a normalização dos valores dos pixels, permitindo melhor desempenho durante o processo de aprendizado.

A arquitetura desenvolvida foi composta por uma Rede Neural Convolucional contendo camadas convolucionais responsáveis pela extração automática de características visuais, seguidas por camadas de agrupamento (pooling), que reduziram a dimensionalidade dos dados

e aumentaram a eficiência computacional do modelo. Ao final da arquitetura, foram utilizadas camadas densas (Dense) para realizar a classificação das imagens nas quatro categorias estabelecidas.

O treinamento foi realizado durante 10 épocas, utilizando o algoritmo de otimização Adam e a função de perda Sparse Categorical Crossentropy, amplamente utilizada em problemas de classificação multiclasse.

Após o treinamento, o desempenho do modelo foi avaliado por meio das métricas Accuracy (Acurácia), Precision (Precisão), Recall (Revocação) e F1-Score. Além disso, foi utilizada uma matriz de confusão para analisar o comportamento das classificações realizadas pela rede neural. Por fim, foi desenvolvido um protótipo de interface utilizando a biblioteca Gradio, permitindo que o usuário realizasse o envio de imagens e obtivesse automaticamente a classificação gerada pela Inteligência Artificial. Essa etapa teve como objetivo demonstrar a aplicação prática da solução desenvolvida e facilitar sua apresentação durante a demonstração do projeto.

4 DESENVOLVIMENTO E EVOLUÇÃO

O desenvolvimento do projeto iniciou-se com a definição do problema de pesquisa, que consistia em verificar a viabilidade da utilização de técnicas de Inteligência Artificial para análise de imagens agrícolas obtidas por drones. Inicialmente, foi realizada uma pesquisa bibliográfica sobre agricultura de precisão, visão computacional, redes neurais convolucionais e utilização de Veículos Aéreos Não Tripulados (VANTs) no monitoramento agrícola.


Após a etapa de fundamentação teórica, foi realizada a busca por uma base de dados adequada para treinamento do modelo. Foi selecionado um conjunto contendo 1.927 imagens agrícolas obtidas por drones, organizadas em quatro classes distintas: Dolomite gypsum, Fallow (left bare), Indian mustard (*Brassica Juncea*) e Rice husk charcoal.

Com a base de dados definida, iniciou-se a implementação da solução utilizando a linguagem python no ambiente Google Colab. Foram utilizadas as bibliotecas TensorFlow e Keras para construção da Rede Neural Convolucional (CNN), além de bibliotecas auxiliares para manipulação dos dados, geração de gráficos e avaliação do desempenho do modelo.

Durante a fase inicial de desenvolvimento, um dos principais desafios encontrados foi a organização e preparação das imagens para treinamento. Foi necessário realizar o carregamento adequado do conjunto de dados, configurar corretamente a divisão entre treinamento e validação e definir parâmetros compatíveis com a arquitetura da rede neural.

Após os ajustes iniciais, foi implementada uma Rede Neural Convolucional composta por camadas convolucionais, camadas de agrupamento (pooling) e camadas densas responsáveis pela classificação de imagens. O treinamento foi realizado durante dez épocas, permitindo que o modelo aprendesse automaticamente os padrões visuais presentes nas imagens agrícolas.


Figura 1 - Evolução da acurácia durante o treinamento da CNN



Fonte: Elaborado pelo autor (2026).

Conforme apresentado na Figura 1, observa-se crescimento progressivo da acurácia ao longo das épocas de treinamento. O modelo apresentou desempenho crescente durante o processo de aprendizado, atingindo níveis próximos de 100% de acerto no conjunto de validação. Esse comportamento demonstra a rede neural foi capaz de aprender adequadamente as características presentes nas imagens utilizadas.

Figura 2 - Evolução do erro (Loss) durante o treinamento




Fonte: Elaborado pelo autor (2026)

A figura 2 apresenta a evolução da função de perda (loss) ao longo do treinamento da rede neural. Observa-se uma redução significativa dos erros à medida que as épocas avançam, indicando que o modelo se tornou progressivamente mais eficiente na classificação das imagens agrícolas. A diminuição da função de perda demonstra que o treinamento ocorreu de forma satisfatória e sem instabilidades significativas.

Após a conclusão do treinamento, foram calculadas métricas de desempenho para avaliar a capacidade de classificação do modelo. Os resultados obtidos demonstraram elevado desempenho da rede neural, atingindo acurácia, precisão, recall e F1-Score próximos de 100%, evidenciando a eficiência da solução da proposta.

Figura 3 - Matriz de confusão do modelo CNN




Fonte: Elaborado pelo autor (2026).

A matriz de confusão apresentada na Figura 3 demonstra o desempenho do modelo no conjunto de validação. Verifica-se que todas as imagens foram corretamente classificadas em suas respectivas categorias, não sendo observadas classificações incorretas. Esse resultado reforça a capacidade da Rede Neural Convolucional em identificar padrões visuais presentes nas imagens agrícolas analisadas.

Com o objetivo de demonstrar a aplicação prática da solução desenvolvida, foi criada uma interface gráfica utilizando a biblioteca Gradio. Essa interface permite que o usuário envie uma imagem agrícola e receba automaticamente a classificação realizada pela Inteligência Artificial.

Figura 4 - Interface do sistema desenvolvido



Fonte: Elaborado pelo autor (2026).

A interface apresentada na figura 4 foi desenvolvida para facilitar a interação entre o usuário e o modelo de Inteligência Artificial. Por meio dela, é possível realizar o envio de imagens de forma simples e obter rapidamente o resultado da classificação realizada pela rede neural.

Figura 5 - Exemplo de classificação realizada pela IA




Fonte: Elaborado pelo autor (2026).

A Figura 5 apresenta um exemplo de utilização do sistema desenvolvido. Nesse teste, uma imagem agrícola foi submetida à análise da rede neural, sendo classificada automaticamente como Indian mustard (Brassica Juncea), com elevado nível de confiança. Esse resultado demonstra o funcionamento prático da solução e confirma a capacidade do modelo em realizar classificações automáticas de imagens agrícolas.

Ao final do desenvolvimento, verificou-se que a utilização de Redes Neurais Convolucionais associadas a imagens capturadas por drones constitui uma alternativa eficiente para automatização da análise agrícola. Os resultados obtidos demonstram o potencial da Inteligência Artificial para auxiliar produtores rurais na identificação de padrões presentes nas lavouras, contribuindo para processos de monitoramento mais rápidos, precisos e eficientes.

Figura 6 - Identificação automática da cobertura vegetal e estimativa do vigor vegetativo



Fonte: Elaborado pelo autor (2026).

A figura 6 apresenta o funcionamento do módulo complementar de estimativa de vigor vegetativo desenvolvido para o sistema. Inicialmente, a imagem é processada para identificação das regiões associadas à vegetação. Em seguida, é calculado o percentual de cobertura vegetal presente na imagem. Com base nesse percentual, o sistema realiza uma classificação simplificada do vigor vegetativo em níveis baixos, médio ou alto. No exemplo apresentado, foi identificada uma cobertura vegetal de 37,15%, resultando na classificação de vigor vegetativo médio.

5 CONCLUSÃO

O presente trabalho teve como objetivo desenvolver uma solução baseada em Inteligência Artificial para análise de imagens agrícolas obtidas por drones, demonstrando o potencial dessas tecnologias no contexto da agricultura de precisão. A partir da utilização de Redes Neurais Convolucionais (CNN), foi possível construir um sistema capaz de classificar automaticamente imagens agrícolas e identificar padrões visuais presentes nas áreas monitoradas.

Os resultados obtidos demonstraram que a metodologia adotada foi eficiente, uma vez que o modelo alcançou elevados índices de desempenho durante os testes realizados. As métricas de avaliação apresentaram resultados satisfatórios, evidenciando a capacidade da rede neural em realizar classificações precisas das imagens pertencentes às diferentes categorias analisadas.

Além da classificação automática das imagens, foi implementado um módulo complementar para estimativa do vigor vegetativo com base na cobertura vegetal identificada nas imagens capturadas por drones. Essa funcionalidade permitiu fornecer informações adicionais sobre o estado da vegetação, contribuindo para uma análise mais próxima das necessidades da agricultura de precisão.

A integração entre drones, visão computacional e Inteligência Artificial demonstrou ser uma alternativa promissora para automatizar tarefas de monitoramento agrícola que tradicionalmente dependem de inspeções manuais. Dessa forma, a solução desenvolvida pode auxiliar produtores rurais na obtenção de informações mais rápidas e precisas sobre suas áreas de cultivo, favorecendo a tomada de decisões e o gerenciamento das lavouras.

Por fim, conclui-se que os objetivos propostos foram alcançados, comprovando a viabilidade da aplicação de técnicas de Inteligência Artificial na análise de imagens agrícolas. Como trabalhos futuros, sugere-se a utilização de bases de dados mais amplas, a integração com sensores multiespectrais e a implementação de índices de vegetação mais avançados, como o NDVI, visando aumentar ainda mais a precisão das análises e ampliar as possibilidades de aplicação da solução desenvolvida.

REFERÊNCIAS

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep Learning. Cambridge: MIT Press, 2016.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. Nature, v. 521, n. 7553, p. 436-444, 2015.

MOLIN, José Paulo. Agricultura de Precisão. São Paulo: Oficina de Textos, 2015.

RUSSELL, Stuart; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Pearson, 2021.

SZELISKI, Richard. Computer Vision: Algorithms and Applications. 2. ed. Springer, 2022.

ZHANG, Changping; KOVACS, John M. The application of small unmanned aerial systems for precision agriculture: a review. Precision Agriculture, v. 13, n. 6, p. 693-712, 2012.